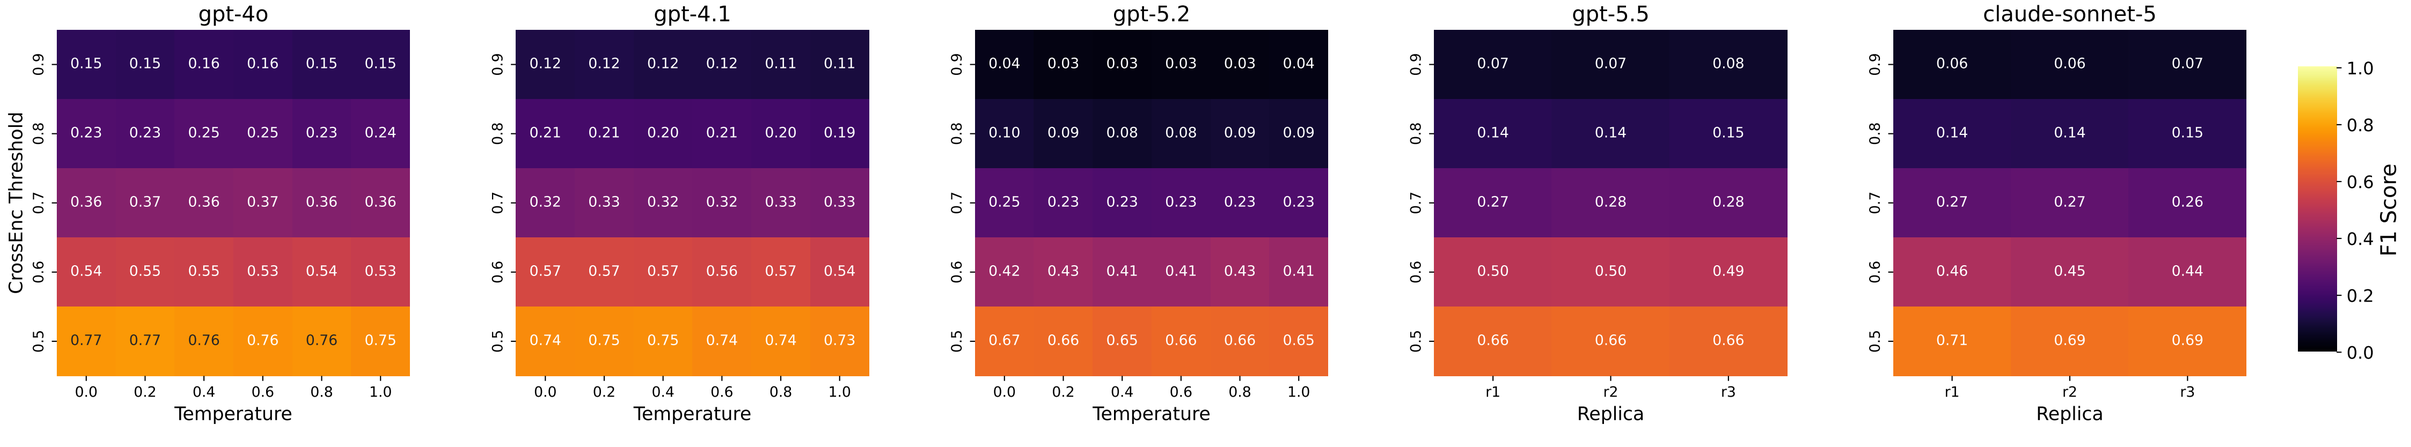
gpt-4o
gpt-4.1
gpt-5.2
gpt-5.5
claude-sonnet-5
CrossEnc Threshold
0.9 0.8 0.7 0.6 0.5
0.15 0.15 0.16 0.16 0.15 0.15
0.23 0.23 0.25 0.25 0.23 0.24
0.36 0.37 0.36 0.37 0.36 0.36
0.54 0.55 0.55 0.53 0.54 0.53
0.77 0.77 0.76 0.76 0.76 0.75
0.12 0.12 0.12 0.12 0.11 0.11
0.21 0.21 0.20 0.21 0.20 0.19
0.32 0.33 0.32 0.32 0.33 0.33
0.57 0.57 0.57 0.56 0.57 0.54
0.74 0.75 0.75 0.74 0.74 0.73
0.04 0.03 0.03 0.03 0.03 0.04
0.10 0.09 0.08 0.08 0.09 0.09
0.25 0.23 0.23 0.23 0.23 0.23
0.42 0.43 0.41 0.41 0.43 0.41
0.67 0.66 0.65 0.66 0.66 0.65
0.07 0.07 0.08
0.14 0.14 0.15
0.27 0.28 0.28
0.50 0.50 0.49
0.66 0.66 0.66
0.06 0.06 0.07
0.14 0.14 0.15
0.27 0.27 0.26
0.46 0.45 0.44
0.71 0.69 0.69
0.0 0.2 0.4 0.6 0.8 1.0
Temperature
r1 r2 r3
Replica
F1 Score
1.0 0.8 0.6 0.4 0.2 0.0